

PROGRAMA DE ASIGNATURA

1. Antecedentes

ESCUELA O UNIDAD	FACULTAD DE INGENIERÍA
PROGRAMA	INGENIERÍA CIVIL INDUSTRIAL
PLAN	ICI PLAN 6, CIN PLAN 2
NOMBRE DE LA ASIGNATURA	PRONÓSTICO DE DATOS E INTELIGENCIA ARTIFICIAL
CÓDIGO	IGR-00869
VERSIÓN AÑO	2025
NIVEL	NIVEL IX CIN, NIVEL IX ICI
TIPO DE ASIGNATURA	PRÁCTICA
RÉGIMEN	SEMESTRAL
MODALIDAD	NO PRESENCIAL
CARÁCTER	OBLIGATORIA
ÁREA DE CONOCIMIENTO	OTRAS INGENIERÍAS Y TECNOLOGÍAS
PRE-REQUISITOS	MACHINE LEARNING

DESCRIPCIÓN DE LA ASIGNATURA

La asignatura Pronóstico de Datos e Inteligencia Artificial se enfoca en desarrollar competencias avanzadas en el diseño, implementación y mejora continua de sistemas predictivos, en procesos empresariales. Para ello, combina modelos predictivos estadísticos tradicionales, técnicas de machine learning, y arquitecturas de inteligencia artificial como redes neuronales recurrentes, convolucionales y transformers. A través de un enfoque práctico y analítico, los estudiantes aprenderán a seleccionar modelos adecuados para generar pronósticos (forecasting) según la naturaleza de los datos y los objetivos del negocio, considerando el equilibrio entre precisión predictiva, eficiencia computacional y sostenibilidad ambiental.

A lo largo del curso, los alumnos aprenderán a evaluar el rendimiento de los modelos predictivos mediante métricas robustas como MAE, RMSE, MAPE y MASE, considerando siempre el equilibrio entre precisión y eficiencia computacional. Un componente clave será el análisis del impacto ambiental de los modelos, donde utilizarán herramientas orientadas a medir y optimizar la huella de carbono de los procedimientos de software.

Como complemento al enfoque principal en forecasting, la asignatura también abordará aplicaciones relacionadas con clasificación en el ámbito empresarial. Los estudiantes explorarán el uso de modelos de clasificación que, empleados con fines de predicción, les permitirá, por ejemplo, anticipar fenómenos como la fuga de clientes (customer churn), aportando una base para que desarrollen estrategias de acción concretas para su retención. Este enfoque amplio permitirá que los estudiantes relacionen de manera efectiva los sistemas de pronóstico con otras áreas críticas de la toma de decisiones empresariales.

Finalmente, el curso guiará a los estudiantes en la implementación de soluciones end-to-end, desde el preprocesamiento de datos hasta el despliegue de modelos en entornos simulados. Trabajarán con bibliotecas especializadas como TensorFlow, PyTorch y Scikit-learn, y aprenderán a automatizar procesos clave como el reentrenamiento de modelos y la detección de deriva de datos (data drift). El proyecto final integrará todos estos elementos, desafiando a los alumnos a resolver un problema real de pronóstico o clasificación predictiva, con énfasis en la interpretabilidad de resultados y la eficiencia operacional.

2. Carga académica

CRÉDITOS ACADÉMICOS	DISTRIBUCIÓN DE HORAS									
4	HORAS CRONOLÓGICAS			HORAS LECTIVAS PEDAGÓGICAS						
	Hrs. Totales	TPE ¹	Hrs. Ped. Lectivas	Presenciales				No presenciales		Hrs Totales
				Teóricas	Laboratorio/Taller	Terreno	Ayudantía	Sincrónicas	Asincrónicas	
	112	64	48	0	0	0	0	72	0	72

3. Contribución al perfil de egreso

COMPETENCIAS GENÉRICAS	DESCRIPTOR	NIVEL
	Autonomía y autoaprendizaje. Evaluar su propio aprendizaje de manera autónoma y reflexiva, utilizando una variedad de recursos y estrategias para planificar y ejecutar un procedimiento que subsane las necesidades detectadas.	Nivel 3: Evaluar su propio aprendizaje de manera autónoma y reflexiva, utilizando una variedad de recursos y estrategias para planificar y ejecutar un procedimiento que subsane las necesidades detectadas
COMPETENCIAS ESPECÍFICAS	DESCRIPTOR	NIVEL
	Construir soluciones tecnológicas avanzadas, a través de la transformación digital mediante la inteligencia artificial	Nivel 3: Construir soluciones tecnológicas avanzadas, a través de la transformación

	(IA) y la ciencia de datos, orientadas a la mejora continua de procesos y proyectos en organizaciones y/o comunidades.	digital mediante la inteligencia artificial (IA) y la ciencia de datos, orientadas a la mejora continua de procesos y proyectos en organizaciones y/o comunidades.
	Diseñar procesos para satisfacer necesidades de optimización de materiales, información y energía, utilizando herramientas de gestión de proyectos, heurísticas de negocio, y computacionales como apoyo a la mejora continua de sistemas complejos de ingeniería y al servicio de industrias y organizaciones inteligentes.	Nivel 3: Diseñar procesos para satisfacer necesidades de optimización de materiales, información y energía, utilizando herramientas de gestión de proyectos, heurísticas de negocio, y computacionales como apoyo a la mejora continua de sistemas complejos de ingeniería y al servicio de industrias y organizaciones inteligentes.

RESULTADOS DE APRENDIZAJE	
1	Analizar los factores que afectan el rendimiento de los modelos de pronóstico basados en inteligencia artificial utilizando datos históricos de una empresa comercial
2	Evaluar la precisión de modelos tradicionales y avanzados de IA en la predicción de demanda mediante la implementación de técnicas de validación cruzada.
3	Desarrollar un sistema de pronóstico utilizando redes neuronales profundas para predecir la demanda de productos en un entorno de retail, optimizando los parámetros del modelo.

4. Unidades de aprendizaje

Nombre de la Unidad I	Contenidos
Fundamentos de Pronósticos y Evaluación de Modelos 12 hrs	Formula de pronósticos para en decisiones estratégicas y problemas empresariales reales.
	Aplica de modelos tradicionales versus avanzados de pronóstico a situaciones específicas.
	Emplea de métricas de evaluación para determinar el rendimiento de los pronósticos y optimizar modelos.

	Analiza Trade-off de la relación precisión-costo para decidir el equilibrio óptimo en la implementación de soluciones de pronóstico.
Nombre de la Unidad II	Contenidos
Redes Neuronales Profundas para Pronóstico 12 hrs	Reconoce arquitecturas de redes neuronales para series temporales (RNN, LSTM, GRU, Convolucionales 1D, transformers) y ejemplos de aplicación.
	Usa herramientas y flujos de trabajo (TensorFlow/Keras, PyTorch, preprocesamiento)
	Optimiza de modelos (Hiperparámetros clave, técnicas para evitar overfitting)
Nombre de la Unidad III	Contenidos
Implementación y Sostenibilidad en Modelos de IA 20 hrs	Despliega y monitoreo considerando herramientas de producción, deriva de datos (data drift), alertas.
	Identifica factores externos, mejora continua, planes de actualización
	Comprende la sustentabilidad en IA
Nombre de la Unidad IV	Contenidos
Proyecto integrador 24 hrs	Conoce la metodología CRISP-DM adaptada
	Aplica en proyecto de la especialidad, con foco en precisión y sostenibilidad.
	Presenta de resultados (Storytelling, análisis de impacto ambiental/operacional)
	Utiliza estrategias para integrar sostenibilidad en los modelos de predicción.
	Diseña un plan de mejora continua en sistemas de predicción.
Evaluación final del logro de los aprendizajes de la asignatura	4 horas

5. Estrategias metodológicas y evaluativas

ESTRATEGIAS METODOLÓGICAS
La asignatura compromete las siguientes estrategias metodológicas activo-participativas: - Aprendizaje basado en problemas (ABP): Resolución de problemas reales para desarrollar análisis crítico y toma de decisiones. - Aprendizaje por proyecto: Creación de proyectos prácticos que integran conocimientos y habilidades avanzadas. - Estudio de casos: Análisis de situaciones reales para proponer soluciones fundamentadas. - Talleres formativos: Actividades prácticas para aplicar herramientas y técnicas específicas. - Discusión guiada: Debates estructurados para reflexionar y profundizar en los contenidos.
PROCEDIMIENTOS EVALUATIVOS
La asignatura contempla los siguientes procedimientos evaluativos:

- Evaluación diagnóstica (1) de tipo conocimiento mediante una prueba escrita con su respectiva pauta de corrección en sala de clases o aula virtual, sin ponderación (solo al inicio de la asignatura).
- Evaluaciones formativas de tipo conocimiento y desempeño mediante talleres grupales, análisis de casos y discusiones guiadas, utilizando pautas de observación, listas de cotejo y rúbricas para valorar el progreso y retroalimentar a los estudiantes (todas las unidades).
- Evaluaciones sumativas: Son tres, de tipo conocimiento, producto y desempeño, aplicando pruebas teórico-prácticas, entregas de proyectos y presentaciones orales, con pautas de corrección o rúbricas. Estas evaluaciones se desarrollan en sala de clases, laboratorio o aula virtual, con ponderaciones distribuidas en un 30% para la Unidad 1, 30% para la Unidad 2, y 40% para la Unidad 3, según se detalla más abajo. Estas tres evaluaciones suman el 100% de la nota de la asignatura, sin examen final.

Detalle de evaluaciones sumativas:

- Sumativa 1 (Unidad 1): 30%. Desarrollo individual. Prueba teórico-práctica. Contenidos: diferencias entre modelos tradicionales (ej. ARIMA) y de IA (ej. XGBoost) en términos de precisión y recursos computacionales; cálculo e interpretación de MAE, RMSE, MAPE, y MASE en un análisis de caso (ej. demanda energética), según corresponda.
- Sumativa 2 (Unidad 2): 30%. Proyecto grupal (código + presentación oral). Contenidos: desarrollo de un modelo de red neuronal (LSTM/GRU) con parámetros optimizados para predecir demanda, pérdida de clientes (customer churn), u otro índice, en un análisis de caso (ej. retail, banca).
- Sumativa 3 ((Unidades 3 y 4): 40%. Proyecto grupal (código + presentación oral). Contenidos: Implementación de un sistema de pronóstico desde inicio a fin (datos → modelo → API); propuesta de Plan de Mejora Continua con monitoreo de drift y reentrenamiento; análisis de impacto ambiental (ej: huella de carbono del modelo).

Evaluaciones Sumativas		
Unidad de Aprendizaje	Instrumento evaluativo	Laboratorio 100%
I	Sumativa de tipo conocimiento, mediante prueba escrita de carácter teórico práctico, usando pauta de corrección.	30%
II	Sumativa de tipo desempeño, mediante trabajos grupales de proyecto, usando rúbrica.	30%
III	Sumativa de tipo desempeño, mediante proyecto evaluado con rúbrica.	20%
III	Sumativa de tipo desempeño, mediante presentación oral con rúbrica.	5%
IV	Sumativa de tipo desempeño, mediante proyecto evaluado con rúbrica.	10%

IV	Sumativa de tipo desempeño, mediante presentación oral con rúbrica.	5%
	Examen final (30%)	Nota de Presentación 70%

La ponderación del promedio de las notas y de la evaluación final para esta asignatura están establecidas en las Disposiciones Académicas, del período académico en curso.

6. Recursos de aprendizaje

BIBLIOGRAFÍA

BIBLIOGRAFÍA BÁSICA

- Bobadilla, J. (2020). Machine Learning y Deep Learning: Usando Python, Scikit y Keras: (1 ed.). RA-MA Editorial. <https://elibro.net/es/lc/santotomas/titulos/222698>
- Casas Roma, J. Bosch Rué, A. & Lozano Bagén, T. (2019). Deep learning: principios y fundamentos: (ed.). Editorial UOC. <https://elibro.net/es/lc/santotomas/titulos/126167>
- Digital, C. (2023). Deep Learning: Unlocking Our Emotions: (1 ed.). Cervantes Digital. <https://elibro.net/es/lc/santotomas/titulos/266126>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Chollet, F. (2021). Deep Learning with Python (2nd Edition). Manning Publications.
- Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2020). Forecasting: Theory and Practice. Wiley.

BIBLIOGRAFÍA COMPLEMENTARIA

- Russell, S., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4th Edition). Pearson.
- Aggarwal, C. C. (2018). Neural Networks and Deep Learning: A Textbook. Springer.
- Hyndman, R. J., & Athanasopoulos, G. (2021). Forecasting: Principles and Practice (3rd Edition). OTexts.

OTROS RECURSOS

- Python con bibliotecas especializadas como TensorFlow, Keras, NumPy, y Pandas para la implementación de modelos de IA y pronósticos.
- Herramientas de visualización de datos como Matplotlib y Seaborn para el análisis de resultados.
- Entornos de desarrollo como Jupyter Notebook o Google Colab para la ejecución de proyectos.